

Predição do Consumo Diário de Água em Data Centers Utilizando Regressão Linear e *Random Forest*

Letícia Vieira França

Universidade Federal de São Paulo (Unifesp)

São José dos Campos, Brasil

leticia.franca@unifesp.br

<https://github.com/leticiavfr/Projeto-Final-IA>

Resumo—O crescimento da Inteligência Artificial tem contribuído para a expansão dos *data centers*, aumentando a preocupação com o consumo de recursos naturais, especialmente água e energia elétrica. Neste trabalho, os algoritmos Regressão Linear e *Random Forest* foram utilizados para prever o consumo diário de água em *data centers*, com o objetivo de comparar o desempenho de cada um dos algoritmos em relação a previsão do consumo diário de água. O estudo foi realizado a partir de uma base de dados contendo informações de várias instalações ao redor do mundo. Os modelos foram analisados com base em métricas de regressão e comparados em relação a capacidade preditiva e ao custo computacional. Os resultados indicaram que o algoritmo *Random Forest* apresentou desempenho superior ao da Regressão Linear, obtendo menores erros de previsão e maior capacidade de explicação da variabilidade dos dados.

Palavras-chave—inteligência artificial, *data centers*, consumo de recursos naturais, regressão linear, *random forest*.

I. INTRODUÇÃO

O crescimento acelerado da Inteligência Artificial (IA) tem aumentado a expansão da infraestrutura de *data centers* (instalações reponsáveis pelo armazenamento, processamento e distribuição de grandes volumes de dados) em todo o mundo. Entretanto, essa expansão também tem aumentado o consumo de recursos naturais, principalmente água e energia elétrica, tornando a sustentabilidade dos *data centers* um tema relevante. Nesse contexto, este trabalho está alinhado aos Objetivos de Desenvolvimento Sustentável (ODS) 6 (Água Potável e Saneamento), 7 (Energia Limpa e Acessível), 12 (Consumo e Produção Responsáveis) e 13 (Ação Contra a Mudança Global do Clima), ao abordar o uso mais eficiente de recursos hídricos e energéticos.

O consumo de água é uma das principais preocupações relacionadas à essas instalações. Em muitos sistemas de resfriamento, a água utilizada é perdida por evaporação, impossibilitando sua reutilização. A alta demanda por energia elétrica, necessária para o processamento computacional e para os sistemas de climatização, contribui para o aumento das emissões de carbono.

Nos últimos anos, estudos têm investigado alternativas para reduzir os impactos ambientais dos *data centers*. Wang et al. [5], por exemplo, implementaram algoritmos de aprendizado

de máquina para otimizar sistemas de resfriamento evaporativo, enquanto Mytton [4] analisou o consumo de água dessas instalações e destacou a necessidade de melhorar sua eficiência hídrica. Apesar desses avanços, ainda existem poucos estudos voltados especificamente à previsão do consumo diário de água em *data centers* utilizando variáveis da própria instalação.

Assim, este trabalho propõe a utilização de técnicas de aprendizado de máquina para prever o consumo diário de água em *data centers*. Para isso, são comparados os algoritmos Regressão Linear e *Random Forest*, utilizando um conjunto de dados contendo mais de 120 mil informações operacionais de instalações distribuídas globalmente. Além da comparação entre os modelos, também é realizada uma análise da influência dos hiperparâmetros do *Random Forest* e da importância das variáveis utilizadas na previsão.

A principal contribuição deste trabalho consiste na avaliação comparativa entre modelos de regressão aplicados à previsão do consumo diário de água em *data centers*, juntamente a uma análise das variáveis mais relevantes para o problema. Dessa forma, obtém-se modelos preditivos com alto desempenho e a compreensão de quais fatores possuem maior influência sobre o consumo hídrico.

II. TRABALHOS RELACIONADOS

Wang et al. [1] propuseram um modelo baseado em técnicas de aprendizado de máquina para otimizar o funcionamento de sistemas de resfriamento evaporativo em *data centers*. Os autores compararam algoritmos como *Random Forest* e *XGBoost* na previsão do desempenho térmico do sistema. Os resultados demonstraram alta precisão na modelagem do comportamento operacional. O estudo destaca que modelos de aprendizado de máquina podem ser utilizados para aumentar a eficiência energética e reduzir custos de operação em *data centers*.

Mytton [2] fez uma revisão sobre o consumo de água em *data centers*, discutindo o aumento da preocupação com o impacto hídrico provocado pela expansão da IA. O trabalho destaca os desafios relacionados à escassez hídrica e à sustentabilidade das grandes instalações computacionais.

Panda e Kim [3] apresentaram um modelo baseado em *Random Forest* para estimar o consumo de água no setor industrial em escala global. O objetivo do estudo foi construir um conjunto de dados capaz de representar o uso industrial de recursos hídricos, auxiliando pesquisas ambientais e de planejamento sustentável. Os resultados destacaram que o algoritmo conseguiu capturar relações complexas entre as variáveis, produzindo estimativas consistentes para diferentes regiões do mundo. O trabalho demonstra a eficiência do *Random Forest* na modelagem de problemas relacionados ao consumo de água.

Alba et al. [4] compararam algoritmos de aprendizado de máquina para prever o consumo de água e energia em uma instituição de ensino. Entre os modelos avaliados, pode-se citar o *Random Forest* e o *Support Vector Regression*. Os desempenhos foram analisados por meio de métricas como RMSE e MAE. Os autores notaram que o *Random Forest* apresentou maior precisão em grande parte dos experimentos.

Herrera et al. [5] investigaram o impacto da expansão da IA sobre o consumo global de água por meio de projeções baseadas em diferentes cenários de crescimento da infraestrutura computacional. O estudo analisa como a demanda por *data centers* pode aumentar a pegada hídrica associada às aplicações de IA nas próximas décadas.

Os trabalhos citados demonstram que técnicas de aprendizado de máquina vêm sendo empregadas em problemas relacionados à sustentabilidade, ao gerenciamento de recursos e à otimização da operação de *data centers*. Porém, observa-se que poucos estudos abordam especificamente a previsão do consumo diário de água utilizando informações operacionais das instalações. Nesse contexto, o presente trabalho contribui ao comparar os algoritmos Regressão Linear e *Random Forest*, analisar a influência do hiperparâmetro $n_estimators$ e identificar as variáveis mais relevantes para a previsão do consumo hídrico em *data centers*.

III. METODOLOGIA

A. Proposta do Trabalho

A proposta deste trabalho consiste na aplicação e comparação de dois algoritmos de aprendizado de máquina para regressão (Regressão Linear e *Random Forest*) com o objetivo de prever o consumo diário de água em *data centers*. Para isso, foi utilizado um conjunto de dados contendo informações operacionais de instalações distribuídas mundialmente, incluindo características como capacidade elétrica, eficiência energética, eficiência no uso da água e consumo diário de energia.

Não foram realizadas modificações nos algoritmos originais de Regressão Linear e *Random Forest*, sendo empregadas as implementações disponibilizadas pela biblioteca *Scikit-learn*. A principal contribuição está na construção de um fluxo completo de análise.

É esperado que essa abordagem produza soluções mais precisas do que modelos lineares tradicionais para esse problema, considerando que o algoritmo *Random Forest* é capaz de representar relações não lineares entre as variáveis de entrada.

Além disso, a avaliação da importância das variáveis fornece maior interpretabilidade ao modelo.

B. Algoritmos Utilizados

1) *Regressão Linear (RL)*: A Regressão Linear é um modelo estatístico para prever uma resposta numérica de uma variável dependente a partir de uma ou mais variáveis independentes. O modelo estabelece uma relação linear entre uma variável dependente e um conjunto de variáveis independentes, ajustando um hiperplano que minimiza o erro entre os valores observados e os valores previstos.

A Regressão Linear foi utilizada como modelo de referência por sua simplicidade computacional e capacidade de modelar relações lineares entre as variáveis, servindo como base para comparação com o modelo *Random Forest*.

2) *Random Forest (RF)*: O algoritmo *Random Forest* combina resultados de saída de múltiplas árvores de decisão para alcançar um único resultado. Durante o treinamento, as árvores são construídas utilizando subconjuntos aleatórios dos dados, para que cada uma aprenda padrões distintos. Cada árvore gera uma previsão para a variável alvo, e o resultado final é obtido pela média das previsões produzidas por todas as árvores.

O *Random Forest* foi escolhido por sua capacidade de modelar relações complexas entre as variáveis e por sua robustez em relação a dados de alta dimensionalidade.

IV. ANÁLISE EXPERIMENTAL

A. Conjunto de dados

A base de dados utilizada neste trabalho foi o *dataset Global Data Center & AI Water/Electricity Usage*, disponibilizado por Ashutosh Singh na plataforma Kaggle. O conjunto de dados fornece uma visão global em série temporal do uso estimado de energia e água em todo o mundo, com dados de 18.110 *data centers* abrangendo o período de 2019 a 2025. No total, são 126.770 registros. Entre as variáveis disponíveis, estão o tipo de sistema de resfriamento, consumo diário de água, consumo diário de energia, eficiência no uso de energia e eficiência no uso de água.

1) *Variáveis utilizadas*: As variáveis utilizadas para a análise estão presentes na Tabela I. De forma geral, elas representam localidade, ano de registro, infraestrutura e consumo energético dos *data centers*. A variável *Daily_Water_Usage_Galons* foi escolhida como variável alvo, sendo utilizada para o treinamento e avaliação dos modelos de aprendizado de máquina.

Após a importação do *dataset* e a análise de colunas disponíveis, colunas de identificadores ou com pouca utilidade preditiva foram excluídas. Dentre elas, estavam *Facility_ID*, *Facility_Name*, *Owner_Company* e *City*. Ademais, a verificação por valores nulos foi realizada, porém nenhum foi encontrado.

A técnica de codificação *one-hot encoding* foi utilizada para transformar variáveis categóricas armazenadas como *object* em variáveis binárias. Como modelos de *Machine Learning* exigem dados numéricos, a técnica citada cria uma coluna exclusiva para cada categoria.

Tabela I
VARIÁVEIS UTILIZADAS

Variável	Descrição
<i>Year</i>	Ano de registro
<i>Country</i>	País de instalação
<i>Facility_Type</i>	Tipo de data center
<i>Estimated_Capacity_MW</i>	Capacidade elétrica estimada
<i>PUE</i>	Eficiência energética
<i>Cooling_System_Type</i>	Sistema de resfriamento
<i>WUE_L_per_kWh</i>	Eficiência hídrica
<i>Daily_Electricity_Usage_MWh</i>	Consumo diário de energia
<i>Surrounding_Water_Stress_Tier</i>	Nível de estresse hídrico regional
<i>Daily_Water_Usage_Gallons</i>	Variável alvo

B. Configuração do Algoritmo e do Ambiente Computacional

Os experimentos foram desenvolvidos na linguagem Python utilizando o ambiente Google Colaboratory (Google Colab), que disponibiliza uma máquina virtual baseada em Linux para execução de códigos. O ambiente utilizado possuía processador virtual Intel Xeon com frequência de 2,0 GHz, 12 GB de memória RAM e sistema operacional Ubuntu Linux. A versão da linguagem utilizada foi o Python 3.12.13.

Para a implementação dos algoritmos e análise dos dados foram empregadas as bibliotecas *Pandas* (2.2.2), para manipulação e processamento do conjunto de dados; *Matplotlib* (3.10.0), para geração dos gráficos; e *Scikit-learn* (1.6.1), para a implementação dos algoritmos de aprendizado de máquina e das métricas de avaliação. Também foram utilizadas as bibliotecas nativas *os*, *zipfile* e *time* para manipulação de arquivos e medição do tempo de execução dos experimentos.

A Regressão Linear foi implementada utilizando a classe *LinearRegression* da biblioteca *Scikit-learn*, mantendo seus parâmetros padrão. O algoritmo *Random Forest* foi implementado por meio da classe *RandomForestRegressor*, sendo avaliadas diferentes configurações do hiperparâmetro *n_estimators*, correspondentes a 10, 50, 100 e 150 árvores de decisão.

Os dados foram separados em três conjuntos: treino (para ajuste dos modelos), validação (comparação e escolha de hiperparâmetros) e teste (avaliação final), sendo 70% para treino, 15% para teste e 15% para validação. Para reduzir o efeito da aleatoriedade nos dados e tornar os resultados estatisticamente mais estáveis, todo o processo de divisão e treinamento foi repetido com 30 sementes distintas (valores inteiros de 0 a 29). O parâmetro *random_state* foi aplicado tanto na função *train_test_split* quanto no construtor do *RandomForestRegressor*, de modo que toda a aleatoriedade envolvida fosse controlada e variasse entre as execuções.

C. Critérios de Análise

1) *Erro Absoluto Médio (MAE)*: O Erro Absoluto Médio representa a média da diferença absoluta entre os valores observados e os valores previstos pelo modelo. Quanto menor seu valor, maior é a precisão das previsões.

2) *Raiz do Erro Quadrático Médio (RMSE)*: A Raiz do Erro Quadrático Médio é a raiz quadrada do Erro Quadrático Médio, que representa a média da diferença ao quadrado entre os valores originais e os valores previstos no conjunto de

dados. A métrica RMSE mede o desvio padrão dos resíduos, dando ênfase a erros absolutos.

3) *Coefficiente de Determinação (R^2)*: O Coeficiente de Determinação mede a proporção da variabilidade da variável dependente que é explicada pelo modelo. Seu valor varia de 0 a 1, sendo que valores mais próximos de 1 indicam melhor capacidade de ajuste.

D. Resultados e Discussão

1) *Comparação dos modelos*: Após o treinamento dos modelos e aplicação das métricas de avaliação, foram geradas tabelas e gráficos com o objetivo de comparar o desempenho da Regressão Linear e do *Random Forest*.

A Tabela II apresenta a comparação de métricas entre os algoritmos, reportando a média calculada sobre as 30 execuções com sementes diferentes. Observa-se que o tempo de treinamento do *Random Forest* foi superior ao da Regressão Linear. Entretanto, o modelo apresentou médias menores de MAE e RMSE, além de um Coeficiente de Determinação (R^2) mais elevado, indicando maior precisão nas previsões e melhor capacidade de ajuste aos dados.

Tabela II
COMPARAÇÃO DE MÉTRICAS (MÉDIA)

Modelo	MAE	RMSE	R^2	Treino (s)	Predição (s)
RL	92025.53	202426.14	0.744	3.03	0.05
RF	2605.60	14821.30	0.998	171.24	0.76

O coeficiente de determinação obtido pelo *Random Forest* ($R^2 = 0.99$) indica que o modelo foi capaz de explicar aproximadamente 99% da variabilidade do consumo diário de água presente no conjunto de teste, enquanto a Regressão Linear explicou cerca de 76%.

Além disso, o gráfico de comparação entre os valores reais e os valores previstos foi gerado para ambos os modelos. Na




Figura 1. Real vs Previsto - Regressão Linear e Random Forest (semente 29).

Figura 1, é possível observar como o modelo de Regressão Linear frequentemente foge dos valores reais. Também observa-se que as previsões do *Random Forest* ficam mais próximas da

reta ideal, indicando maior precisão na estimativa do consumo diário de água.

A diferença entre os resultados obtidos pelos dois modelos evidencia que a relação entre as variáveis explicativas e o consumo diário de água não é linear. Dessa forma, a capacidade do *Random Forest* de modelar relações não lineares contribuiu para seu desempenho superior.




Figura 2. Distribuição do R^2 (boxplot).

A Figura 2 apresenta o boxplot que compara a distribuição do R^2 dos dois modelos ao longo das 30 execuções. Cada caixa representa o intervalo interquartil (faixa que concentra os 50% centrais dos valores observados), enquanto a linha interna indica a mediana. As hastes correspondem aos valores mínimo e máximo, e pontos fora desse intervalo são classificados como *outliers*. Os valores de R^2 do *Random Forest* se concentram em uma faixa mais alta e com menor dispersão do que os da Regressão Linear. O modelo obteve melhores resultados em média e também apresentou maior estabilidade.

2) *Influência dos hiperparâmetros*: O algoritmo *Random Forest* possui hiperparâmetros que podem ser ajustados para influenciar seu desempenho. Dentre eles, há o $n_estimators$, que define a número de árvores de decisão que compõem a floresta. Um número maior de árvores melhora a precisão, mas aumenta o tempo de computação.

Para esta análise, foram gerados quatro modelos com 10, 50, 100 e 150 árvores de decisão. Os experimentos foram realizados com a semente 29 (última das 30 sementes avaliadas). Os resultados são apresentados na tabela a seguir:

Tabela III
INFLUÊNCIA DO HIPERPARÂMETRO $n_estimators$ NO DESEMPENHO DO MODELO *Random Forest*

$n_estimators$	Treino (s)	Predição (s)	MAE	RMSE	R^2
10	17.27	0.10	3202.06	17204.66	0.99815
50	86.74	0.41	2750.22	16620.12	0.99827
100	175.71	0.82	2687.02	16601.4	0.99828
150	263.67	1.29	2670.53	16328.87	0.99834

Observa-se que o aumento de árvores de decisão proporcionou melhorias nas métricas de avaliação. Entretanto, essas melhorias diminuíam com o aumento do número de árvores, enquanto o tempo de treinamento cresceu de forma praticamente linear.

Apesar de o modelo com 150 árvores apresentar o melhor desempenho, a diferença em relação ao modelo com 100 árvores foi pequena quando comparada ao aumento do tempo de treinamento.

3) *Importância das variáveis*: O algoritmo *Random Forest* possibilita estimar a importância de cada variável utilizada durante o treinamento do modelo, identificando quais variáveis exerceram maior influência na previsão do consumo diário de água dos *data centers*.

A Figura 3 apresenta as cinco variáveis com maior importância segundo o modelo treinado.




Figura 3. Importância das variáveis.

Observa-se que a variável *Estimated_Capacity_MW* foi a que apresentou maior importância, indicando que a capacidade elétrica instalada do *data center* é o fator que mais contribui para a previsão do consumo diário de água. Esse resultado é coerente, considerando que instalações com maior capacidade demandam maior infraestrutura de processamento e resfriamento, aumentando o consumo hídrico.

Em seguida, destacam-se as variáveis *WUE_L_per_kWh* e *Daily_Electricity_Usage_MWh*. A primeira representa a eficiência no uso da água durante a operação do *data center*; a segunda está diretamente relacionada ao consumo energético da instalação. A importância dessas variáveis sugere que a eficiência hídrica e a demanda energética exercem papel significativo na estimativa do consumo de água.

Por fim, variáveis como *Cooling_System_Type_Evaporative* e *PUE* apresentaram importância menor quando comparadas às três primeiras. Isso indica que sua contribuição para a previsão foi mais limitada. Dessa forma, pode-se considerar que o consumo diário de água é explicado principalmente por características relacionadas à capacidade operacional da instalação, ao consumo de energia e à eficiência no uso da água.

4) *Discussão*: Os resultados obtidos ao longo das 30 execuções com sementes distintas demonstram que o algoritmo *Random Forest* apresentou desempenho superior ao da

Regressão Linear em todas as métricas de avaliação utilizadas. A baixa variação observada nos resultados entre as diferentes sementes indica que as conclusões não dependem de uma partição específica dos dados. O *Random Forest* modela relações mais complexas e não lineares, o que provavelmente contribuiu para sua maior capacidade preditiva. Além disso, o alto valor do Coeficiente de Determinação (R^2) obtido pelo modelo indica que grande parte da variabilidade do consumo diário de água foi consistentemente explicada pelas variáveis utilizadas no treinamento, sem depender da semente utilizada.

A análise da influência do hiperparâmetro $n_estimators$ foi feita com a semente 29, mantendo as mesmas métricas da análise principal. Os resultados mostraram que o aumento do número de árvores proporcionou melhorias nas métricas de desempenho do modelo, mas esses ganhos tornaram-se menores à medida que o número de árvores cresceu, enquanto o tempo de treinamento aumentou. Isso evidencia que a escolha do número de árvores deve considerar os requisitos de desempenho e o tempo disponível para treinamento.

A análise da importância das variáveis apresentou resultados coerentes com o contexto operacional dos *data centers*, considerando que instalações com maior capacidade computacional tendem a consumir mais energia e demandar sistemas de resfriamento mais intensivos, o que reflete diretamente no consumo de água.

Apesar dos resultados obtidos pelo *Random Forest*, algumas limitações devem ser consideradas. O conjunto de dados utilizado é composto por estimativas de consumo, não por medições reais de cada instalação. Além disso, variáveis como $WUE_L_per_kWh$ possuem relação direta com o consumo de água, o que pode facilitar a tarefa de previsão e contribuir para o alto desempenho observado.

V. CONCLUSÃO

Este trabalho teve como objetivo desenvolver modelos de aprendizado de máquina capazes de prever o consumo diário de água em *data centers*, além de analisar os fatores que mais influenciam esse consumo. Para isso, foram implementados os algoritmos de Regressão Linear e *Random Forest*, utilizando um conjunto de dados contendo informações sobre capacidade elétrica, consumo de energia, eficiência hídrica e características operacionais de *data centers* ao redor do mundo.

Os resultados obtidos demonstraram que ambos os modelos foram capazes de realizar previsões do consumo diário de água, porém o algoritmo *Random Forest* apresentou desempenho superior ao da Regressão Linear em todas as métricas de avaliação utilizadas. Além disso, a análise da importância das variáveis mostrou que a capacidade elétrica estimada da instalação, a eficiência no uso da água e o consumo diário de energia foram os fatores que mais contribuíram para a qualidade das previsões, destacando a forte relação entre esses atributos e o consumo hídrico dos *data centers*.

Dessa forma, conclui-se que técnicas de aprendizado de máquina podem ser aplicadas com sucesso na previsão do consumo de água em *data centers*. A utilização de modelos

preditivos pode contribuir para os Objetivos de Desenvolvimento Sustentável. Quanto ao ODS 6 (Água Potável e Saneamento), a capacidade de antecipar o consumo hídrico das instalações permite orientar estratégias de uso mais racional da água; em relação ao ODS 7 (Energia Limpa e Acessível), a forte associação identificada entre consumo energético e consumo hídrico sugere que ganhos de eficiência energética nos *data centers* tendem a reduzir a demanda por água; quanto ao ODS 12 (Consumo e Produção Responsáveis), os modelos desenvolvidos oferecem suporte ao planejamento operacional mais consciente; por fim, em relação ao ODS 13 (Ação Contra a Mudança Global do Clima), a redução do consumo de água e energia em *data centers* contribui para a diminuição das emissões de carbono associadas à operação dessas instalações.

REFERÊNCIAS

- [1] M. Herrera, et al., "Sustainable AI Infrastructure: A Scenario-Based Forecast of Water Footprint Under Uncertainty," *Journal of Cleaner Production*, 2025. [Online]. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0959652625018785>. Acesso em: 13 jun. 2026.
- [2] E. L. Alba, et al., "Water and Electricity Consumption Forecasting at an Educational Institution Using Machine Learning Models," arXiv, 2024. [Online]. Disponível em: <https://arxiv.org/abs/2410.19709>. Acesso em: 13 jun. 2026.
- [3] M. R. Panda and Y. Kim, "Gridded Global Dataset of Industrial Water Use Predicted Using the Random Forest," *Scientific Data*, vol. 11, 2024. [Online]. Disponível em: <https://www.nature.com/articles/s41597-024-04148-5>. Acesso em: 13 jun. 2026.
- [4] D. Mytton, "Data Centre Water Consumption," *npj Clean Water*, vol. 4, 2021. [Online]. Disponível em: <https://www.nature.com/articles/s41545-021-00101-w>. Acesso em: 13 jun. 2026.
- [5] Z. Wang, et al., "Time-Series Machine Learning for Predictive Optimisation of a Highly Efficient Evaporative Cooling System," *Building Services Engineering Research and Technology*, 2025. [Online]. Disponível em: <https://journals.sagepub.com/doi/abs/10.1177/01436244251315047>. Acesso em: 13 jun. 2026.
- [6] A. Singh, "Global Data Center & AI Water/Electricity Usage," Kaggle, 2025. [Online]. Disponível em: <https://www.kaggle.com/datasets/ashyou09/global-data-center-and-ai-waterelectricity-usage>. Acesso em: 13 jun. 2026.
- [7] Scikit-learn Developers, "Scikit-learn Documentation," [Online]. Disponível em: <https://scikit-learn.org/stable/>. Acesso em: 21 jun. 2026.
- [8] A. Nair, "Comparing Linear Regression and Random Forest Regression Using Python," *Plain English*, 2024. [Online]. Disponível em: <https://python.plainenglish.io/comparing-linear-regression-and-random-forest-regression-using-python-23cc1b8c579>. Acesso em: 21 jun. 2026.
- [9] Environmental and Energy Study Institute, "Data Centers and Water Consumption," [Online]. Disponível em: <https://www.eesi.org/articles/view/data-centers-and-water-consumption>. Acesso em: 23 jun. 2026.
- [10] Machine Learning University, "Linear Regression," [Online]. Disponível em: <https://mlu-explain.github.io/linear-regression/>. Acesso em: 25 jun. 2026.
- [11] IBM, "What is Random Forest?," IBM Think. [Online]. Disponível em: <https://www.ibm.com/br-pt/think/topics/random-forest>. Acesso em: 25 jun. 2026.